

Три потребительских типа России: структура сверхинертна, переходы редки — и доказуемы

2 016 муниципальных образований × 24 месяца безналичных трат. Протокол зафиксирован до прогонов (предрегистрация, тег `pregreg-v1`), число типов выбрано по устойчивости разбиений, а не «на глаз»; **все 15 поправок к собственному протоколу опубликованы**. Переходы между типами допускаются только с доказательством сдвига профиля — 177 из 3 107 кандидатов (173 события одного сезонного экскурса + 4 рождения типов).



Восемь гипотез доведены до проверки — четыре убиты нами же, а не жюри


Здесь — ход мысли, а не только финиш: каждая строка читается «думали → проверили → что вышло». Полная хроника поворотов — журнал из 15 отклонений (PREREG_DEVIATIONS.md); протокол зафиксирован до первого прогона (тег prereg-v1).

ГИПОТЕЗА	ПРОВЕРКА	ИТОГ
Сходство рядов — по сырым корреляциям	медиана $r = 0,906$ по 2 031 120 парам: все ряды растут вместе с ценами	отказ → сходство только по остаткам после вычитания общего месяца (−0,006)
Обучаемый граф (M11) сильнее ручного правила	при перезапусках совпадает 23% рёбер; один узел-хаб собрал 2 015 связей из 2 016	отказ → гейт устойчивости обязателен; прод — простое правило
Лучшая мера бенчмарка — лучшая опора типологии	M3 выиграла бенчмарк (0,398), но стабильного разбиения на ней нет вовсе ($k=1$)	опровергнута → типология на M2; «мера ≠ опора» — находка
Одного прогона Leiden достаточно	разные seed-прогоны расходятся: совпадение разбиений 0,44–0,73	отказ → консенсус 25 прогонов: совпадение 0,93
Переходы — это «волна маркетплейсов»	у типа-экскурса доля маркетплейсов ниже, чем у периферии	отказ → «сезонный экскурс»: $177 = 173 \text{ события} + 4 \text{ рождения типов}$
Моногорода — отдельный потребительский тип	перевес над случайностью 1,14×; 177 из 190 сидят в периферийном типе	не подтвердилась → отрицательный результат опубликован
Бустинг предскажет переходы лучше простого правила	на горизонте 1 мес простое правило выигрывает у бустинга (0,051 против 0,029)	частичный отказ → публикуем простое правило, числа — на листе 11
Конвейер чист от утечек данных	тест-приманка поймал признак, знавший ответ (согласие seed-прогонов)	признак удалён, метрики пересчитаны — честное 0,062 на горизонте 3 мес

СВЕРЕНО · ПРОТОКОЛ ИМЕНОВАНИЯ



Три типа безналичной России: периферия, сервисные ядра, Северо-Запад

Каждый тип — понятие с описанием: какие территории входят и чем отличаются (три независимых описателя — правило вкладов Миркина, дерево решений, SHAP-важности признаков; их согласие публикуется). Имя тип получает, только если покрывает ≥ 60% его территорий и встречается там ≥ 2 раз чаще, чем в среднем по стране (протокол именования); подтипы — с пометкой пониженной стабильности.



«Россия-1» Зубаревич раскалывается на два типа — моногорода не выделяются вовсе

Типология проверена независимыми списками. Главная новизна: агломерационная Россия не едина по безналичному профилю — 89% «России-1» делятся между ядрами и Северо-Западом (в 5,5 / 4,4 раза чаще случайного уровня).



- **Моногорода не отделяются** (перевес над случайным всего 1,14×; 177 из 190 — в периферии): моногород — институциональный, а не потребительский портрет. (Совпадение с числом переходов — 177 — случайное.)
- **Татарстан 43/43 в периферии** при зарплате на уровне РФ (+4,8%): безналичные траты на 18% ниже.
- **Азнакаевский р-н (нефтяной)**: зарплата +31% к медиане своего типа — профиль при этом периферийный. Зарплата ≠ безналичное потребление.
- Сопоставимость вместо «среднего по региону»: тип — это бенчмарк, внутри которого МО сравнимы честно.

ЧЕСТНАЯ ОГОВОРКА

Spearman = -1,00 при n=3 типах: точный p = 1/3. Это sanity-check порядка (еда 45,9→36,1→33,3% против зарплат 48→86→115 тыс. ₽), не статистическое доказательство.

Сырые корреляции рядов вырождены инфляцией (r = 0,91) — сходство считаем по остаткам


Все ряды растут вместе с ценами: медианная корреляция сырых приростов 0,906 по 2 031 120 парам — сеть из них тривиальна. Поэтому из каждого месяца вычитаем среднее по стране (демеанинг): медиана корреляции падает до −0,006, и сходство становится содержательным.

- Значения — **рубли на жителя в месяц** (per-capita из источника; население второй раз не делим).
- 6 долей категорий → **лог-отношения CLR** (стандарт для долевых данных: сравниваем пропорции, а не рубли); нулей в данных нет, поправки на ноль не нужны. «Прочее» = 1-Σ5, медиана 28% — сигнал, не мусор.
- 2 190 рядов → **2 016 полных** (174 неполных исключены с публичным реестром: Бурятия только-2023, Дагестан/Чечня только-2024).
- Преемники муниципальных реформ **не склеиваем** — ряд = формальная территория.
- Дамп обрывается 2024-12: **2025-го на уровне МО не существует** — out-of-time нигде не обещаем.
- **Данные ограничивают выводы — и это написано раньше выводов** (предрегистрация, тег prereg-v1).

РАСПРЕДЕЛЕНИЕ ПОПАРНЫХ КОРРЕЛЯЦИЙ ПРИРОСТОВ (ВЫБОРКА 40 ТЫС. ПАР)

F11. Почему демеанинг: сырые корреляции вырождены

попарная корреляция приростов log трат; выборка 40 тыс. случайных пар МО



Данные: СберИндекс 2023-2024 · CC BY-SA 4.0 · расчёты: outputs/main · make report

48 384

строки панели (2 016 МО
× 24 мес)

0,906 →

−0,006

медиана корреляции до /
после демеанинга

174

неполных ряда исключены
(реестр публикуется)

Правило рёбер — формальное и проверяемое: 12 900 рёбер, ноль изолятов, одна компонента

Сходство двух территорий = корреляция их остатков. Каркас кандидатов: 10 ближайших по сходству + страховочная тройка на узел (чтобы никто не остался без связи); дальше — фильтр значимости BH-FDR, который удерживает долю ложных находок при 2 031 120 одновременных проверок ($q = 0,05$). География — отдельным слоем: вес затухает с автодорожным расстоянием ($\exp(-d/150 \text{ км})$). Список рёбер, перестроенных по подпериодам, почти не пересекаются (3%) — помесечная топология нестабильна, поэтому каркас строится один раз на всех данных, а месячная динамика живёт в весах: один набор рёбер + 24 вектора весов.



- **11 мер сходства + 3 анти-примера** прогнаны через предрегистрированный гейт (пропускной тест: устойчивость к пертурбациям рёбер).
- **Обучаемый граф (M11) провалил гейт:** при перезапусках на подвыборках совпадает лишь 23% рёбер; один узел-хаб собрал 2 015 связей из 2 016. Сложность не купила топологию.
- Лаговые корреляции и DTW (сравнение рядов с допуском сдвига по времени) — тоже в бенчмарке (M4/M6/M7): полная ширина критерия, не одно правило.
- **Сеть проста по правилу и строга по фильтру** — каждое ребро объяснимо и перепроверяемо.

М3 выиграл бенчмарк мер (0,398 против 0,280) — и схлопнул типологию в один кластер

Композит из пяти опор, зафиксированных до прогонов: качество кластеров (ICVI), устойчивость к перезапускам, согласие между месяцами, восстановление истины на синтетике, структурная ценность. Отрыв М3 больше ошибки измерения. Но правило устойчивости — «плато»: разбиение обязано воспроизводиться при перезапусках — на графе М3 не находит ничего, кроме тривиального $k = 1$. Прод-типология — на сильнейшей мере, прошедшей этот гейт (М2).

- Отрыв М3 = 0,118 при ошибке измерения 0,013 (парный бутстрэп, 1 000 перепарываний); проверка весов: при 2 000 случайных перетасовок весов композита М3 — самый частый победитель (47% случаев) — вывод не куплен весами.
- М2 (прод) = одна корреляция остатков итогового ряда; М3 = среднее пяти покатегорийных корреляций остатков (в z -пространстве). М2 — пятая по композиту, но совпадение разбиений при перезапусках 0,942 — лучший баланс из прошедших гейт.
- Находка: **измерительное качество меры и структурная устойчивость — разные свойства сети**. Обе таблицы публикуются полностью.


ЧЕСТНАЯ ОГОВОРКА

SBM-подобное ядро синтетики даёт сетевым мерам домашнее преимущество — оговорено в отчёте; LFR-реплики после retry-провалов частично из 5 графов (не маскируется).

КОМПОЗИТ МЕР (КРАСНЫМ — НЕ ПРОШЛИ ГЕЙТ)

F2. М3 выиграл бенчмарк мер — и схлопнул типологию

композит пяти предрегистрированных ног; прод-опора М2 — золотым; < 0 = ниже среднего по мерам




Данные: СберИндекс 2023–2024 · CC BY-SA 4.0 · расчёты: outputs/main · make report

СВЕРЕНО · PATTERN ДО 1E-16

Число типов — не «локоть на глаз», а правило устойчивости: стабилен только макро-уровень k = 3

Девять базисных методов четырёх семейств (атрибутивные, сетевые, атрибутированные, спектральные) плюс консенсусный слой поверх них × шесть внутренних индексов качества кластеров — ICVI: силуэт SW, Калински–Харабаш CH/N, S_Dbw, изолируемость AVI, унифицируемость AVU, модулярность MQ. Вычисления сверены с эталонной библиотекой Pattern до 16-го знака. Победитель композита — spectral_knn; в прод идёт Leiden-консенсус (Leiden — метод поиска сообществ в сети; консенсус = голосование 25 перезапусков): единственный, кто совмещает авто-k (сам выбирает число типов) с плато-стабильностью k=3 («плато» = диапазон силы детализации γ , где разбиение воспроизводится). Обе версии композита публикуются.

ТЕЙТ УСТОЙЧИВОСТИ: СОВПАДЕНИЕ РАЗБИЕНИЙ (ARI) ПРИ 25 ПЕРЕЗАПУСКАХ ПО СИЛЕ ДЕТАЛИЗАЦИИ γ



Данные: СбериИндекс 2023-2024 · CC BY-SA 4.0 — [рас-бери outputs/main — make report](#)

- Одиночный Leiden при каждом перезапуске даёт другой ответ (совпадение разбиений ARI 0,44–0,73; ARI = 1 при тождественных) → консенсус из 25 прогонов: совпадение 0,93 при силе детализации γ из предрегистрации.
- Прод-типология против 200 случайных разбиений тех же размеров: отрыв в единицах разброса случайных (z) — SW 5,4; CH/n 453; S_Dbw -20; AVI 174; MQ 263. Случайные разбиения не дотягивают ни по одному индексу.
- k-means (k=6) почти догоняет консенсус по устойчивости (0,9136 против 0,9178) при 110× скорости. Но сам число типов не выбирает, и сетевой чистоты (MQ против случайного нуля) не даёт — консенсус остаётся продом.

ТОП КОМПОЗИТА МЕТОДОВ (ПОЛНЫЙ — TABLE_METHODS.PARQUET)

МЕТОД	K	NMI НА СИНТЕТИКЕ	КОМПОЗИТ
spectral_knn	6	0,895	0,868
kefrin	6	0,900	0,760
leiden_consensus (прод)	3	0,909	0,679
kmeans	6	0,783	-0,047


ЧЕСТНЫЕ ОГОВОРКИ

AVU при k = 3 почти константен для любого разбиения (разброс 200 случайных $\approx 2,3 \cdot 10^{-16}$) — индекс неинформативен на малом k, его z = 0,47 не интерпретируем. Родственные пары «индекс × метод» помечены флагами: модулярность MQ роднится с сетевыми методами, силуэт — с k-means.

177 ДОКАЗУЕМЫХ

Из 3 107 смен типа доказуемы 177 – инертность сильнее помесячного шума

Гейт эволюции считает разницу, а не похожесть: соседние месяцы различаются на 0,12 ($= 1 - 0,876$), а та же типология при случайном потрясении 5% рёбер – на 0,35 ($= 1 - 0,655$). Разница месяцев меньше шумовой во всех 23 парах → месячная эволюция недоказуема; это доказанная сверхинертность, а не отсутствие событий: переход допускается, только если метка не мерцала туда-обратно, 25 перезапусков согласны $\geq 80\%$, а сдвиг профиля трат сильнее, чем у 75% всех территория-месяцев. Метки динамики живут в своём реестре (помесячные типы 0–8), поверх – макро-слой $k = 3$; карта между пространствами опубликована (type_id_map).



- Устойчивость типологии на горизонтах 1/3/6 мес – средний ARI 0,88/0,88/0,86 (медианы 0,90–0,92): «кто ты» меняется редко.
- **177 = 173 события одного сезонного экскурса (тип 4) + 4 рождения типов** – не «177 историй», а одна волна + четыре дебюта, и это сильнее: структура динамики читается.
- Порог не подогнан: при строгом (сдвиг сильнее, чем у 95% территория-месяцев) – 27 безусловных фактов; при нашем (75%) – 177; при мягком (50%) – 276. Нарратив строим от ядра.
- **Инертность – свойство системы; редкость переходов (0,37% = 177 из 48 384 территория-месяцев) – свойство экономики.** Каждый допущенный переход верифицирован сдвигом профиля.

У каждого перехода — имя и сдвиг профиля; ассоциация, не пророчество


177 карточек переходов с драйверами в сырых единицах — рублях и долях (важности TreeSHAP) — плюс event-study ±6 мес против похожих территорий без перехода: профиль переходчиков сближается с контрольной группой за 2–3 месяца до события, после — разрыв не закрывается (n=177, различия внутри 95% доверительного интервала — ассоциация, не причинность). Предсказуемость — отдельный вопрос, и ответ честный: лист 11.

- **Балтайский (Саратовская обл.):** вероятность перехода в топ-2% по модели ещё до события; **Черноярский (Астраханская)** — в топ-22%. Предсигнал существует — но слабый (лист 11).
- **Поселение Киевский (Новая Москва):** рождение нового типа 2023-12 — топ-драйверы карточки: соседство с типом-источником (+3,9) и сезонность (+2,3), дальше зарплата и маркетплейс-динамика.
- Тип 4 (сезонный экскурс): 202 → 537 → 174 МО → слит в тип 0; из него же родился тип 7.
- Канал 4→0 в event-study — без контрольной группы: пустая панель показана как результат, а не скрыта.

EVENT-STUDY: ПРОФИЛЬ ДО/ПОСЛЕ ПЕРЕХОДА (MATCHED-КОНТРОЛЬ)

F6. Соседский состав съезжается к переходу и не расходится

обе серии — Δ к своему уровню в t=−6; matched-контроль 5-NN (n=177 событий); ленты — 95% CI (аналитич., консервативные); ассоциация, не причинность



Данные: СберИндекс 2023–2024 · CC BY-SA 4.0 · расчёты: outputs/main · make report

Бустинг не обыграл простое правило — публикуем простое, а радар подписываем «непроверено»

Проверка строго по времени: обучение только на прошлом, экзамен на будущем, с буфером-эмбарго. Метрика — PR-AUC (качество списка подозреваемых при редком классе); рядом всегда уровень бесплатного угадывания: 0,018 на горизонте 1 мес, 0,031 — на 3 мес. Итог на горизонте 1 мес — ничья между простым и сложным: в среднем по выборке лидирует логит на 5 признаках (0,051 против 0,029 у бустинга), внутри отдельных месяцев — бустинг; по заранее зафиксированному правилу (§2.3 спеки) публикуем самое простое — margin-rank: ранг по «запасу близости» (насколько территория глубже сидит в своём типе, чем близка к чужому; кто на границе — кандидат на переход). Признак, случайно знавший ответ (согласие seed-прогонов), пойман нашим же тестом-приманкой и удалён; бустинг без него остаётся движком радара и SHAP-профилей.



- На горизонте 3 мес бустинг выходит вперёд: 0,062 против 0,044 у простого правила и 0,031 у угадывания по частоте — вдвое выше базы, но абсолютная сила скромная: переходы редки. По заранее зафиксированному правилу продуктом идёт простое правило, а бустинг без утечки остаётся движком радара и SHAP-профилей; оба числа публикуются, вердикт — в model_metrics.json.
- Радар смены типа на 2024-12: 202 МО в топ-дециле, **у всех unverified=true** — января 2025 в данных нет, верифицировать нечем. Таргет радара — любая смена метки (1 043 в обучении), шире 177 доказуемых переходов. Скор дискретен: порядок внутри дециля — не ранг.
- Цена ошибки: пропуск перехода дороже ложной тревоги — порог радара есть функция потерь, не гиперпараметр.
- Простая модель опубликована не как поражение ML, а как дисциплина отбора: усложнение обязано покупаться числом.

Вся Россия сходится в один клуб по маркетплейсам — и остаётся тремя типами

Тест сходимости Phillips–Sul (наша реализация log-t теста: сближаются ли траектории территорий во времени): по маркетплейсам+продовольствию — один глобальный клуб, все три критерия пройдены (статистика log-t = +0,18 при пороге −1,65; дисперсия и наклон сходимости — в норме). Клубы не совпадают с типами (совпадение $\leq 0,06$ по ARI): сходимость идёт внутри типов, не стирая их.

- **Лэг-лидерство** (кто за кем повторяет динамику с задержкой): 4 437 направленных связей из 2 031 120 пар. Нуль-модель — ряды с перемешанными фазами (та же сезонность, убитая синхронность): связь считаем при корреляции $\geq 0,834$, а 99-й перцентиль случайных — 0,680.
- Топ-«маяки» — периферия: средняя исходящая степень типа 0 = 2,52 против 0,31 у метрополисов.
- Рёбра лидерства не локальнее случая (1,3% против 2,5% в пределах 150 км) — лидерство не про соседство.
- Синхронность с задержкой $\neq$ причинность: общий толчок (сезон, новость) может рисовать ту же картину — читаем «кто за кем следует», а не «кто кого двигает».
- Глубже всех в поле — не «уникально»: у одного конкурента есть зачаточный lead-lag по типам; признаём это в отчёте.
- **Маркетплейс-волна — общероссийская сходимость; типология остаётся структурой различий, не уровней.**

ТОП-«МАЯКИ» ПОИМЁННО · ИСХОДЯЩАЯ СТЕПЕНЬ В ГРАФЕ ЛИДЕРСТВА		
МУНИЦИПАЛИТЕТ	РЕГИОН	OUT-DEG
Тазовский р-н	ЯНАО	87
Кочковский р-н	Новосибирская обл.	85
Сургутский р-н	ХМАО — Югра	49
Новоселицкий м.о.	Ставропольский край	32
г.о. Буй	Костромская обл.	29
Абанский р-н	Красноярский край	26

Маяки — преимущественно периферия (средний out-deg типа 0 = 2,52 против 0,31 у ядер): сигнал идёт не из столиц. **1 клуб** сходимости по маркетплейсам+продовольствию (3/3 критерия); клубы ортогональны типам (ARI $\leq 0,06$).

MAKE REPRODUCE

Восемь ограничений названы до ваших вопросов — каждое число воспроизводимо одной командой

Ограничения: окно 24 мес; нет 2025 на уровне МО; $k=3$ — потолок стабильности (подтипы с пометкой); гейт 23/23 — динамика только узловая; безналичное $\neq$ все расходы; драйверы умеренны; 174 МО исключены + 10 островов на fallback; устойчивость $k=3$ к вариациям правила рёбер ($kNN-k$, q , $\lambda=150$ км, гео-слой) не пересчитана — записано в долг честно (журнал, №14).

- **Предрегистрация** до всех прогонов (тег `prereg-v1`) + журнал из 15 отклонений, включая реестры расхождений, найденных независимыми аудитами (19 проверяющих 06–07.10, комиссия 09.10).
 - **make reproduce**: данные → панель → граф → кластеры → динамика → бенчмарк → интерпретация → отчёт; снимок конфига и лог каждого прогона.
 - **158 тестов** зелёные; чистый клон поднимается; таблица «артефакт → команда → run» в `outputs/main/README.md`.
 - Числа отчёта генерируются кодом из артефактов (шаблон + `numbers.json`); константы построения сети — из лога прогона графов (`graph_summary.json`); два независимых аудита чисел пройдены (07.10, 09.10).
 - **С 36 месяцами данных**: out-of-time на 2025-м, log-t с окном 24 вместо 16, мощнее событийный слой.
- 15

отклонений в журнале — включая найденные аудитами после прогонов
- 158

тестов pytest, все зелёные
- 1 команда

make reproduce — от сырых данных до отчёта